

ROTEIRO DE AULA PRÁTICA

Engenharia de Requisitos para ML com GR4ML

Caderno de Exercícios do Grupo
Preencha os templates de cada fase durante a aula

Centro de Informática — CIn/UFPE
Especialização em Deep Learning · Disciplina: Engenharia de Software para IA

Grupo (nome dos integrantes)	Projeto da disciplina
Breno Alexandre de Albuquerque Santos	Detector de Anomalias em Métricas de Servidores (SMD)
Erasmio de Melo Gusmão	Detector de Anomalias em Métricas de Servidores (SMD)
Gabriel Victor Alves Santana	Detector de Anomalias em Métricas de Servidores (SMD)
João Mateus Queiroz Moreira	Detector de Anomalias em Métricas de Servidores (SMD)
João Pedro da Silva Rodrigues	Detector de Anomalias em Métricas de Servidores (SMD)
Leonardo Canuto de Oliveira Magalhães	Detector de Anomalias em Métricas de Servidores (SMD)
Orlando Gomes dos Reis Neto	Detector de Anomalias em Métricas de Servidores (SMD)
Pedro Oliveira Pessoa Guerra	Detector de Anomalias em Métricas de Servidores (SMD)

Links oficiais: https://www.cs.toronto.edu/~soroosh/gr4ml_language.html
https://www.cs.toronto.edu/~soroosh/gr4ml_toy.html

Como usar este caderno

Este material acompanha o roteiro de aula prática de Engenharia de Requisitos com o framework GR4ML (Goal-Oriented Requirements Engineering for Machine Learning). Cada fase da aula está organizada da mesma forma, para facilitar o acompanhamento:

-  **Ideia central** — uma explicação simples do que a fase/ passo quer resolver, sem jargão técnico.
-  **Exemplo** — um exemplo já resolvido, usando o caso de uma plataforma de streaming que quer reduzir cancelamento de assinaturas (nosso 'fio condutor' do início ao fim).
-  **Entregável** — a frase que diz exatamente o que vocês precisam ter em mãos ao final daquele passo.
-  **Espaço para preencher** — um template em branco para o grupo completar com o próprio projeto, durante a aula.
-  **Checkpoint** — um ponto de parada para o professor validar o progresso do grupo antes de seguir adiante.

Objetivo da atividade

Capacitar os alunos a elicitar, modelar e alinhar requisitos de negócio com decisões de design analítico e pipelines de dados utilizando o GR4ML, garantindo que o modelo de Machine Learning atenda a um valor real de negócio — e não apenas a uma métrica técnica isolada.

Cronograma sugerido

Fase	Duração	Conteúdo
Fase 0 — Alinhamento	20 min	Escopo do projeto, stakeholder principal e dor de negócio
Fase 1 — Business View	45 min	Atores, objetivos, indicadores, decisões e perguntas de negócio
Fase 2 — Analytics Design View	45 min	Tipo de análise, tarefas de ML, algoritmos, softgoals e métricas
Fase 3 — Data Preparation View	45 min	Fontes de dados, transformações e pipeline até o dataset final
Fase 4 — Dos modelos aos requisitos	30 min	Tradução dos modelos em Requisitos Funcionais, Não-Funcionais e de Dados

As três visões do GR4ML, em uma tabela

Visão	Pergunta que responde	Quem pensaria assim, na vida real	O que sai dela
1. Business View	Quem precisa de quê, e por quê?	Gestor / dono do produto	Diagrama Ator → Goal → Decision Goal → Question Goals
2. Analytics Design View	Que modelo resolve isso, com qual qualidade?	Cientista de dados	Tarefas de ML, algoritmos e métricas ligadas aos softgoals
3. Data Preparation View	De onde vêm os dados e como chegam prontos?	Engenheiro de dados	Pipeline de dados brutos até features prontas



FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



ENTREGÁVEL DESTE PASSO: Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



Espaço para o grupo preencher

O Coordenador de Operações de TI de uma frota de servidores precisa saber quando uma máquina passa a operar fora do padrão. Hoje isso depende de limiares fixos por métrica e da inspeção manual de painéis: com 38 métricas por máquina, degradações que só aparecem na combinação dos sinais passam despercebidas até virarem incidente, enquanto os limiares disparam mais alertas do que o plantão consegue triar — o resultado é detecção tardia e desgaste da equipe. Como o SMD é público e anonimizado, este stakeholder é um cenário hipotético do exercício, e os indicadores adotados se limitam ao que é mensurável sobre o próprio dataset.

1 FASE 1 — Business View (Visão de Negócio)

45 minutos · mapeando intenções estratégicas, sem pensar em algoritmos ainda

Objetivo desta fase: mapear as intenções estratégicas do negócio e como o ML pode apoiar a tomada de decisão humana.

PASSO 1.1 Identificar o Ator de negócio

Pergunte: quem vai usar essa solução no dia a dia? Essa pessoa representa qual papel na organização?

💡 Exemplos de Atores

- *Streaming* → *Gerente de Retenção de Clientes*
- *Fraude* → *Gerente de Prevenção a Fraudes*
- *Saúde* → *Médico Oncologista*
- *Hospital (fluxo de atendimento)* → *Coordenador de Enfermagem*

🔗 **ENTREGÁVEL DESTE PASSO:** Uma tabela com 1 linha por ator, contendo nome do ator e papel na organização (2 a 4 atores costuma bastar).

Nome do Ator	Papel na organização
A01 — Analista de Operações / SRE	Usuário principal. Acompanha as métricas do servidor, recebe sinais de comportamento incomum, inicia a triagem e registra o resultado da investigação.
A02 — Coordenador de Operações de TI / Observabilidade	Stakeholder decisor. Acompanha a confiabilidade do monitoramento, define prioridades de investigação e decide quando o detector deve ser mantido, recalibrado ou treinado novamente.

PASSO 1.2 Definir o Goal (objetivo) e anotar expectativas de qualidade

Goal: o que esse ator quer alcançar, de forma mensurável. Indicador: a métrica numérica que mostra progresso desse Goal. Além disso, anotem (ainda de forma informal) frases do stakeholder sobre o que ele valoriza além do número principal — isso será formalizado como Softgoal só na Fase 2.

💡 Exemplo (streaming)

- *Goal: "Reduzir o cancelamento de assinaturas em 15% este ano"*
- *Indicador: taxa mensal de churn (%) — atual: 5% · meta: 4,25%*
- *Anotação informal de qualidade: "O time de retenção mencionou que a lista de clientes em risco precisa estar pronta toda segunda-feira de manhã, sem exceção."*

🔗 **ENTREGÁVEL DESTE PASSO:** Para cada ator: o Goal, o Indicador (com valor atual e meta, se souberem) e 2–3 frases de qualidade esperada, em linguagem do negócio (ainda sem termos técnicos).

Ator	Goal (objetivo)	Indicador (métrica)	Expectativas de qualidade (informal)
A01 — Analista de Operações / SRE	Reduzir o tempo entre o início de um comportamento anômalo e sua identificação e triagem, diminuindo a dependência de inspeção manual contínua.	Indicador de negócio: tempo mediano entre a emissão do alerta e o início da triagem, ainda não instrumentado no contexto operacional. Proxy técnico: recall de instantes/janelas anômalos no conjunto de teste. Valor atual no benchmark da machine-1-1: 88% de recall. Meta proposta: manter recall de pelo menos 85% e reduzir o tempo de triagem em 30% em um piloto futuro.	Degradações que só aparecem na combinação dos sinais não devem passar despercebidas até virarem incidente. O alerta precisa chegar em tempo útil para a triagem. O resultado deve indicar o período e as dimensões que mais contribuíram para o desvio, sem afirmar uma causa raiz que os dados anonimizados não permitem identificar.
A02 — Coordenador de Operações de TI / Observabilidade	Reduzir o esforço manual e manter um mecanismo de alertas confiável, consistente e útil para priorizar a investigação.	Indicador de negócio: esforço necessário para revisar os alertas gerados, ainda não mensurado no contexto operacional. Proxies técnicos: precisão e percentual de janelas sinalizadas. Valor atual no benchmark da machine-1-1: 25,3% de precisão. Meta técnica proposta: superar 25,3% de precisão sem reduzir o recall abaixo de 85%; a meta de redução do esforço manual deverá ser definida e validada em um piloto.	O volume de falsos alarmes deve ser administrável. Alertas semelhantes devem receber tratamento consistente. O desempenho e os limites do detector devem ser verificáveis por versão.

PASSO 1.3 Decision Goal — a decisão que o ator precisa tomar

Uma decisão é sempre uma escolha entre opções — algo que alguém faz repetidamente. Se vocês não conseguem descrever uma escolha concreta, ainda não acharam a decisão certa.



Exemplos

- *Streaming*: "Decidir para quais clientes oferecer um desconto de retenção este mês" (opções: desconto A, desconto B, nenhuma ação)
- *Fraude*: "Decidir se uma transação deve ser bloqueada, sinalizada para revisão manual, ou aprovada"
- *Hospital*: "Decidir qual paciente deve ser atendido primeiro na triagem"



Cuidado com este erro comum

"Entender os clientes" não é uma decisão — é um desejo vago. Pergunte sempre: decidir entre o quê?



ENTREGÁVEL DESTES PASSOS: Uma frase por ator, no formato: '[Ator] precisa decidir [entre quais opções], com que frequência'.

DG01 — O Analista de Operações / SRE precisa decidir, a cada alerta, entre investigar imediatamente, manter a situação em observação ou registrá-la como não acionável após uma verificação inicial.

DG02 — O Coordenador de Operações de TI / Observabilidade precisa decidir, a cada avaliação ou nova versão do detector, entre manter o padrão de referência e o limiar atuais, recalibrar o limiar ou solicitar novo treinamento.

PASSO 1.4 Question Goals — as perguntas que respondem à decisão

Desdobrem o Decision Goal em uma ou mais perguntas específicas que o modelo de ML precisa responder para apoiar a decisão. Especifiquem também o tipo de pergunta (quem/o quê/quando...), o tempo verbal (passado/presente/futuro) e a frequência necessária da resposta.

 **Exemplos**

- *Streaming*: "Quais clientes têm alta chance de cancelar a assinatura nos próximos 30 dias?" → tipo: quem · tempo: futuro · frequência: mensal
- *Fraude*: "Essa transação específica é fraudulenta?" → tipo: o quê · tempo: presente · frequência: tempo real
- *Hospital*: "Qual paciente tem maior risco de piora nas próximas 2 horas?" → tipo: quem · tempo: futuro · frequência: tempo real

 **ENTREGÁVEL DESTE PASSO:** Para cada Decision Goal, uma ou mais Question Goals, indicando tipo, tempo verbal e frequência.


Question Goal (a pergunta)	Tipo	Tempo (passado/presente/futuro)	Frequência
QG01 - Este instante (ou janela) da série temporal da máquina apresenta comportamento anômalo?	O quê	Presente	A cada nova janela de métricas
QG02 - Quais dimensões das métricas mais contribuíram para o erro de reconstrução da janela sinalizada como anômala?	Quais	Presente e passado recente	A cada anomalia detectada
QG03 - Qual é o padrão de comportamento normal de cada máquina, usado como referência de comparação?	O quê	Presente, com base no histórico	A cada treinamento ou recalibração do modelo
QG04 - O desempenho da versão atual do detector permanece dentro das metas de precisão, recall e volume de alertas em comparação com a versão de referência?	Quanto	Presente comparado ao histórico	A cada avaliação, recalibração ou nova versão

Nota de escopo — Esta Business View descreve o sistema-alvo. Na entrega atual, a validação é offline e restrita à machine-1-1, com janelas de 50 amostras; expansão para as 28 máquinas, operação em tempo real e integração com o fluxo humano de alertas ficam fora do escopo atual. Como as dimensões do SMD são anonimizadas, o sistema pode localizar sinais associados ao desvio, mas não afirmar a causa raiz. No conjunto de teste desse recorte, 2.694 de 28.479 instantes

(9,46%) são anômalos; esse valor é a prevalência da classe, não o desempenho do detector. A localização por dimensão é um requisito do sistema-alvo e ainda não está implementada no protótipo atual.

 Entregável final da Fase 1

Desenhem (à mão, em slide, ou em ferramenta de diagramação) um diagrama conectando: Ator → Goal → Decision Goal → Question Goal(s), com os indicadores e as anotações informais de qualidade ao lado do Goal.



2 FASE 2 — Analytics Design View

45 minutos · traduzindo a pergunta de negócio em especificação técnica

Objetivo desta fase: traduzir as perguntas de negócio da Fase 1 em especificações técnicas de Machine Learning — e é aqui que formalizamos os Softgoals.

PASSO 2.1 Tipo de análise

Para cada Question Goal da Fase 1, classifiquem o tipo de análise necessária.

Tipo	O que faz	Exemplo
Preditiva	Prever um valor futuro ou desconhecido	Prever se o cliente vai cancelar
Descritiva	Resumir/explicar o conjunto de dados	Agrupar clientes em perfis de comportamento
Prescritiva	Recomendar a melhor ação entre opções	Recomendar qual desconto oferecer a cada cliente

 **ENTREGÁVEL DESTE PASSO:** Classificação (Preditiva/Descritiva/Prescritiva) para cada Question Goal, com uma frase justificando.

Question Goal	Tipo de análise	Justificativa
<i>Este instante (ou janela) da série temporal da máquina apresenta comportamento anômalo?</i>	Preditiva	O modelo estima, a partir do padrão de normalidade aprendido, se o valor observado das métricas foge do esperado. Como a resposta não é conhecida a priori, trata-se de uma tarefa preditiva.
<i>Quais dimensões das métricas mais contribuíram para o erro de reconstrução da janela sinalizada como anômala?</i>	Descritiva	A pergunta não estima um valor novo, e sim resume e explica o comportamento já observado num trecho anômalo, apontando quais dimensões mais contribuíram para o desvio.
<i>Qual é o padrão de comportamento normal de cada máquina, usado como referência de comparação?</i>	Descritiva	Trata-se de caracterizar o comportamento típico do conjunto de treino, que não contém anomalias, servindo de base para as demais análises.
<i>O desempenho da versão atual do detector permanece dentro das metas de precisão, recall e volume de alertas em comparação com a versão de referência?</i>	Descritiva	Consiste em comparar métricas de desempenho (precisão, recall, etc) com metas e uma versão de referência estabelecidas. Portanto, trata-se de uma tarefa descritiva de monitoramento, em vez de preditiva.

PASSO 2.2 Tarefa de ML e algoritmos candidatos

Desçam um nível de abstração: que tarefa técnica de ML corresponde a essa análise, e quais algoritmos poderiam resolvê-la? Listem do mais simples ao mais sofisticado — ainda não é hora de escolher 'o melhor'.

💡 Exemplo (streaming — "prever cancelamento")

- Tarefa de ML: Classificação Binária (vai cancelar / não vai cancelar)
- Algoritmos candidatos: regra manual (ex.: 'sem login há 20+ dias'), Regressão Logística, Random Forest, XGBoost, Rede Neural

Se a tarefa parecer grande demais, quebrem em sub-tarefas (ex.: 'cancelamento voluntário' vs. 'cancelamento por falha de pagamento' — causas e dados diferentes).

📌 **ENTREGÁVEL DESTE PASSO:** Para cada Meta Analítica: a tarefa de ML correspondente e uma lista de 2–4 algoritmos candidatos.

Meta Analítica	Tarefa de ML	Algoritmos candidatos
<i>Detecção de anomalia por instante (comportamento fora do padrão na série)</i>	Detecção de anomalias em séries temporais multivariadas via erro de reconstrução, com aprendizado semi-supervisionado (treino apenas com dados normais)	Isolation Forest, Autoencoder em PyTorch, LSTM-Autoencoder.
<i>Localização das métricas responsáveis pela anomalia (interpretation_label)</i>	Análise pós-hoc do erro de reconstrução por dimensão, para ranquear quais das 38 métricas mais contribuíram para o desvio detectado	Erro de reconstrução por dimensão, extraído do Autoencoder ou do LSTM-Autoencoder já treinados; score de anomalia por atributo do Isolation Forest, usado como checagem cruzada de baixo custo
<i>Modelagem do padrão normal de cada máquina (baseline de comportamento)</i>	Aprendizado não supervisionado de representação, a partir do conjunto de treino, sem uso de rótulos	Isolation Forest, Autoencoder, LSTM-Autoencoder

PASSO 2.3 Formalizar os Softgoals

Transformem as anotações informais de qualidade da Fase 1 (Passo 1.2) em Softgoals formais — requisitos de qualidade que vão pesar na escolha do algoritmo.

💡 Exemplos, com a origem no negócio

- "Não quero muitos alarmes falsos" (fraude) → Softgoal: Baixa taxa de Falso Positivo / Alta Precisão
- "Preciso entender o motivo da recomendação" (saúde) → Softgoal: Explicabilidade
- "A lista precisa estar pronta toda segunda de manhã" (streaming) → Softgoal: Baixa latência / lote compatível com o prazo
- Softgoals técnicos que o time de dados pode trazer, mesmo sem o stakeholder ter pedido: Custo de treino/operação, Privacidade dos dados, Robustez a mudanças de comportamento (drift)

📌 **ENTREGÁVEL DESTE PASSO:** Lista de 3–5 Softgoals formais, cada um citando de qual anotação da Fase 1 ele se origina (ou indicando que é um softgoal técnico adicional).

Softgoal	Origem (frase do stakeholder ou 'técnico')
<i>Baixa taxa de falso positivo / alta precisão</i>	Stakeholder — "os limiares fixos disparam alertas em volume maior do que o plantão consegue triar". O detector precisa ser mais seletivo que o mecanismo que já frustra a equipe hoje, senão apenas troca a origem do ruído.
<i>Interpretabilidade / localização da anomalia</i>	Stakeholder — "a inspeção manual de painéis com 38 métricas simultâneas é o que consome a equipe". Um alerta que aponta o instante sem indicar as dimensões devolve o analista à mesma varredura que motivou o projeto."
<i>Custo computacional de treino viável</i>	técnico — "o pipeline roda em ambiente local em CPU, sem acesso a uma GPU dedicada."
<i>Cobertura de degradações multivariadas</i>	Stakeholder — "degradações que só aparecem na combinação dos sinais passam despercebidas até virarem incidente". Refere-se a falha específica que escapa do monitoramento por limiar isolado, e a que justifica um modelo que aprenda o comportamento conjunto das 38 métricas.

PASSO 2.4 Vincular Softgoals a métricas de ML tangíveis

🌟 O "pulo do gato" do GR4ML

Todo Softgoal precisa virar uma métrica técnica mensurável, ou ele fica bonito no papel e não influencia nada na prática. Alunos de computação tendem a otimizar só a Acurácia — mas se o negócio exige Explicabilidade, um modelo caixa-preta sem SHAP/LIME viola um requisito de negócio, mesmo acertando mais.

💡 Exemplos de vínculo Softgoal → Métrica

- *Fraude*: "Evitar perturbar clientes inocentes" → *alta Precisão / baixa taxa de Falso Positivo*
- *Saúde*: "Explicabilidade" → *uso obrigatório de SHAP/LIME, ou restrição a modelos interpretáveis*
- *Streaming*: "Compatível com o prazo semanal" → *tempo de inferência em lote < 2h para toda a base*

📌 **ENTREGÁVEL DESTE PASSO:** Uma tabela cruzando Algoritmos (Passo 2.2) × Softgoals (Passo 2.3), com a métrica usada em cada cruzamento, e uma conclusão de qual algoritmo o grupo escolheria.

Algoritmo	Softgoal 1 (Precisão)	Softgoal 2 (Interpretabilidade)	Softgoal 3 (Custo)	Softgoal 4 (Recall)
<i>Isolation Forest</i>	Boa precisão como baseline; por ser um método de árvores, tende a errar anomalias contextuais que dependem da ordem temporal	Média: o score de anomalia pode ser decomposto por atributo, indicando quais das métricas mais pesaram no isolamento	Muito baixo: treina em segundos, sem GPU e sem definição prévia de arquitetura de rede	Média: alcança combinação de sinais num mesmo instante, mas não degradação que se desenvolve ao longo do tempo, que é a falha relatada pelo stakeholder.

Algoritmo	Softgoal 1 (Precisão)	Softgoal 2 (Interpretabilidade)	Softgoal 3 (Custo)	Softgoal 4 (Recall)
<i>Autoencoder</i>	Boa precisão em anomalias pontuais; o erro de reconstrução por instante é direto de calcular	Média-alta: erro de reconstrução por dimensão é nativo da arquitetura, facilitando o ranking de métricas	Baixo-médio: poucas camadas, treina em CPU em tempo razoável.	Alta: reconstrói a janela inteira, aprendendo a correlação conjunta das 38 métricas ao longo de vários instantes.
<i>LSTM-Autoencoder</i>	Tende a melhorar precisão em anomalias contextuais, por capturar dependência temporal entre instantes	Média: erro por dimensão ainda calculável, mas mistura sinal temporal, dificultando a leitura direta	Médio-alto: treino sequencial é mais custoso, ainda viável em CPU para uma única máquina do SMD	Alta: modela dependência temporal explicitamente.

Conclusão do grupo — qual algoritmo escolheriam e por quê:

O grupo escolheria o Autoencoder em PyTorch como modelo principal, já que o repositório já tem pytorch como

dependência e prevê treinar redes neurais para a detecção. O Autoencoder aprende a reconstruir o comportamento

normal das 38 métricas e sinaliza anomalia quando o erro de reconstrução foge do esperado, respondendo diretamente à pergunta de detecção por instante.

PASSO 2.5 Conectar de volta ao indicador de negócio

Fechem o ciclo com a Fase 1: expliquem como a melhoria esperada no modelo se traduz em melhoria no indicador de negócio.

Exemplo (streaming)

- "Se o modelo identificar corretamente 80% dos clientes que vão cancelar, e a campanha de retenção converter 30% deles, esperamos reduzir o churn mensal de 5% para ~4,2%."

 **ENTREGÁVEL DESTE PASSO:** Um parágrafo curto conectando o desempenho esperado do modelo ao Indicador definido no Passo 1.2.

Quanto mais cedo o modelo identificar um comportamento fora do padrão, com poucos falsos positivos, menos a equipe de operação depende de inspeção manual das métricas para perceber que algo está errado.

Isso reduz o tempo entre o início de uma anomalia e sua identificação, o que se conecta ao indicador de negócio: quanto melhor o desempenho do modelo em precisão e recall, mais próximo o indicador tende a ficar da meta definida pelo grupo.

CHECKPOINT

Antes de seguir para a Fase 3, garantam que cada Softgoal tem uma métrica associada — não deixem nenhum 'bonito no papel'.

3 FASE 3 — Data Preparation View

45 minutos · conectando os algoritmos às fontes de dados reais

Objetivo desta fase: conectar os algoritmos escolhidos às fontes de dados reais necessárias para treiná-los e alimentá-los.

PASSO 3.1 Fontes de dados (entidades e atributos)

Identifiquem as entidades e atributos do mundo real necessários para o modelo — mesmo que hipotéticos.

Exemplo (streaming)

- *Cadastro do Cliente: nome, idade, cidade, data de assinatura*
- *Histórico de Visualização: o quê assistiu, quando, por quanto tempo*
- *Atendimentos ao Suporte: data, motivo, se foi resolvido*
- *Logs de Pagamento: forma de pagamento, se houve falha de cobrança*

 **ENTREGÁVEL DESTE PASSO:** Lista das tabelas/fontes de dados brutos, com 3–5 campos principais de cada uma.

Fonte de dados (tabela)	Principais campos/atributos
Métricas Operacionais do Servidor (train e test)	38 métricas anônimas de infraestrutura de servidores de uma grande companhia de internet. Índice temporal implícito (posição da linha, sem coluna de data). Sem cabeçalho. Valores já normalizados.
Rótulo de anomalia (test_label)	Indicador de anomalias: binário (0 = normal, 1 = anômalo). Alinhado por posição ao arquivo de teste.

PASSO 3.2 Data Operations — transformações

Descrevam as transformações necessárias para os dados brutos virarem features (colunas prontas para o modelo).

Tipos de tratamento, com exemplos

- *Tratamento de nulos: preencher ou descartar registros incompletos*
- *Normalização: colocar variáveis em escalas comparáveis*
- *One-Hot Encoding: transformar categorias (ex.: forma de pagamento) em colunas binárias*
- *Agregações temporais: calcular 'horas assistidas por semana' a partir de logs brutos*
- *Integração: juntar tabelas usando o ID do cliente como chave*

 **ENTREGÁVEL DESTE PASSO:** Lista numerada das transformações aplicadas, na ordem em que ocorrem, do dado bruto até a tabela final.

Nº	Transformação aplicada	Tabela(s) de origem
1	Limpeza: valores não numéricos convertidos para NaN e linhas com NaN removidas, preservando o índice original. No teste, o descarte é alinhado — a linha com NaN em qualquer uma das duas tabelas é removida de ambas simultaneamente, mantendo o alinhamento entre test e test_label	train, test, test_label

Nº	Transformação aplicada	Tabela(s) de origem
2	Conversão para NumPy array: converte os DataFrames limpos em arrays NumPy; a tabela test_label é achatada para vetor unidimensional (numpy.ravel())	train, test, test_label
3	Padronização por z-score: média e desvio estimados apenas no treino e reaplicados a validação e teste; desvio zero é substituído por 1 para evitar divisão por zero	train, test
4	Janelamento em sequências deslizantes: cada amostra passa a ser uma janela de 50 timesteps consecutivos, avançando de 1 em 1	train, test

PASSO 3.3 Dataset final e Pipeline

Mostrem a 'tabela final' que o modelo realmente usa — uma linha por unidade de análise, uma coluna por feature — e conectem-na diretamente às tarefas de ML da Fase 2.


Exemplo de dataset preparado (streaming)

• Colunas: *Cliente_ID* | *Dias sem logar* | *Horas assistidas/semana* | *Nº reclamações (3 meses)* | *Já teve falha de pagamento?* | *Cancelou (rótulo)*

 **ENTREGÁVEL DESTE PASSO:** Exemplo de tabela final (pode ser fictício, poucas linhas) + um diagrama simples de pipeline: Fontes brutas → Transformações → Dataset Final → Algoritmo.

Coluna (feature)	Descrição	De qual fonte / transformação vem
segmento_temporal	Unidade de análise do modelo: uma sequência de 50 timesteps consecutivos (deslocamento de 1), com as 38 métricas padronizadas em cada timestep. A ordem interna é preservada, pois é dela que o autoencoder extrai o padrão temporal.	Métricas Operacionais do Servidor / transformações 1, 2, 3 e 4
is_anomaly (label)	Binário, presente só no conjunto de teste. É usado apenas na avaliação final.	Rótulo de Anomalia / alinhamento janela e timestep

Pipeline de dados



CHECKPOINT

Um colega de fora do grupo, lendo o pipeline, deveria entender de onde vem cada coluna da tabela final.

Ferramentas recomendadas

Como o GR4ML estende conceitos do i* (iStar), os alunos podem utilizar:

- **Ferramentas de diagramação geral:** Miro, Lucidchart ou Draw.io, criando uma legenda própria para os elementos do GR4ML:
 - Retângulos arredondados → Goals (Strategic Goal, Decision Goal, Question Goal)
 - Nuvens → Softgoals
 - Hexágonos → Tasks/Algoritmos
- **Ferramentas acadêmicas baseadas em i*:** para quem preferir mais formalismo, a piStar tool, adaptada com estereótipos do GR4ML, ajuda na modelagem orientada a objetivos.

Verificação final

Antes de entregar, completem esta frase única, sem inventar nada que não esteja documentado nas fases anteriores. Se alguma parte não existir no material do grupo, é sinal de que uma fase ficou incompleta — voltem e revisem.

Frase de verificação

"Para ajudar [Ator] a decidir [Decision Goal], respondendo à pergunta [Question Goal], vamos usar [Algoritmo], que satisfaz os softgoals [Softgoals] medidos por [Métricas], usando os dados [Dataset Preparado] vindos de [Fontes de Dados]. Isso deve impactar o indicador [Indicador] em [magnitude esperada]."

Preencham a frase com o projeto de vocês

Para ajudar o Analista de Operações / SRE (A01) a decidir, a cada alerta, entre investigar, observar ou registrar como não acionável (DG01), respondendo à pergunta "esta janela da série apresenta comportamento anômalo?" (QG01), vamos usar um Autoencoder em PyTorch treinado apenas com dados normais, que satisfaz os softgoals de alta precisão, interpretabilidade por dimensão, custo de treino viável e cobertura de degradações multivariadas, medidos por precisão, recall, erro de reconstrução por dimensão e treino concluído sem GPU dedicada, usando janelas de 50 timesteps das 38 métricas padronizadas por z-score vindas das Métricas Operacionais do Servidor e do test_label (só na avaliação). Isso deve impactar o indicador de tempo até a identificação da anomalia, sinalizando ao menos 85% dos eventos anômalos conhecidos do SMD, com precisão acima da taxa base do conjunto (9,46%).



FASE 4 — Dos Modelos aos Requisitos

30 minutos · transformando os diagramas GR4ML em uma lista de requisitos formal

Até aqui, o grupo construiu três diagramas/modelos. Mas um diagrama, sozinho, ainda não é um documento de requisitos — é preciso 'traduzir' cada elemento do modelo em frases claras, testáveis, que um time de engenharia consiga implementar e verificar. Essa tradução segue sempre o mesmo caminho: cada elemento do GR4ML já modelado nas fases anteriores dá origem a um tipo específico de requisito.



Por que isso importa

Um Decision Goal ou um Softgoal, por si só, é uma intenção — não uma instrução que um desenvolvedor consiga implementar ou testar. A elicitação só termina de fato quando a intenção vira um requisito redigido de forma objetiva, rastreável até o elemento do modelo que o originou.

Mapa de tradução: do elemento do GR4ML ao tipo de requisito

Elemento já modelado	Tipo de requisito gerado	Pergunta-guia para redigir
Decision Goal + Question Goal + Insight (Fase 1)	Requisito Funcional (RF)	O que exatamente o sistema precisa calcular ou entregar?
Softgoal + Métrica associada (Passo 2.3–2.4)	Requisito Não-Funcional (RNF)	Que qualidade o sistema deve garantir, e como ela será medida?
Entidades + Dataset Preparado + Transformações (Fase 3)	Requisito de Dados (RD)	Que dados precisam ser coletados, integrados e tratados, e de onde vêm?
Indicador (Passo 1.2)	Critério de Aceitação do conjunto de requisitos	Como saberemos, no negócio, que os requisitos implementados geraram valor real?

PASSO 4.1 Redigir os Requisitos Funcionais (RF)

Um Requisito Funcional descreve uma capacidade que o sistema deve ter. Ele nasce da junção entre a decisão (Decision Goal), a pergunta que a apoia (Question Goal) e o insight que a responde (Fase 1).



Modelo de frase (template)

• "O sistema deve [ação/cálculo], a partir de [dados de entrada], para permitir que [Ator] [decisão apoiada]."



Exemplo preenchido (streaming)

• "O sistema deve calcular uma pontuação de risco de cancelamento (0 a 100) para cada cliente ativo, a partir do histórico de uso, suporte e pagamento dos últimos 12 meses, atualizada semanalmente, para permitir que o Gerente de Retenção decida quais clientes recebem desconto."



ENTREGÁVEL DESTE PASSO: Um Requisito Funcional (RF) redigido para cada Insight identificado na Fase 1, seguindo o template acima.

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-01	O sistema deve calcular um escore de anomalia para cada janela de 50 timesteps consecutivos, a partir do erro de reconstrução das 38 métricas padronizadas, para permitir que o Analista de Operações / SRE (A01) identifique os intervalos que se afastam do padrão normal aprendido.	QG01 — "Esta janela apresenta comportamento anômalo?" · DG01

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-02	O sistema deve classificar cada janela avaliada como normal ou anômala, comparando seu escore de anomalia ao limiar vigente, para permitir que o A01 decida, a cada alerta, entre investigar imediatamente, manter em observação ou registrar como não acionável.	DG01 (as três opções de decisão) · QG01
RF-03	O sistema deve disponibilizar, para cada janela sinalizada como anômala, o erro de reconstrução decomposto por métrica, ordenado da maior para a menor contribuição, para permitir que o A01 inicie a triagem sem varrer manualmente as 38 séries. Trata-se de um requisito do sistema-alvo, ainda não implementado no protótipo atual, conforme a nota de escopo da Fase 1	QG02 — "Quais dimensões mais contribuíram para o erro?" · DG01
RF-04	O sistema deve aprender o padrão de comportamento normal da máquina monitorada, a partir da partição de treino isenta de anomalias e sem uso de rótulos, para permitir que o A01 avalie cada nova janela contra uma referência explícita, e não contra limiares fixos por métrica.	QG03 — "Qual é o padrão normal de referência?" · DG01
RF-05	O sistema deve persistir o modelo treinado, o limiar de anomalia e as estatísticas de padronização aplicadas, para permitir que o Coordenador de Operações de TI (A02) reaplique a mesma referência a novas janelas sem repetir o treinamento.	QG03 · DG02 (manter a referência vigente)
RF-06	O sistema deve derivar o limiar de anomalia do percentil configurado sobre os escores da partição de treino, registrando o valor aplicado em cada execução, para permitir que o A02 decida entre manter o limiar vigente, recalibrá-lo ou solicitar novo treinamento.	DG02 (recalibrar o limiar)
RF-07	O sistema deve calcular e registrar precisão, recall e F1 da versão avaliada, comparadas aos rótulos do conjunto de teste, além do percentual de janelas sinalizadas como anômalas, para permitir que o A02 verifique se o desempenho permanece dentro das metas antes de manter ou substituir a versão em uso.	QG04 — "O desempenho permanece dentro das metas?" · DG02

PASSO 4.2 Redigir os Requisitos Não-Funcionais (RNF)

Um Requisito Não-Funcional descreve uma qualidade que o sistema deve garantir — nasce diretamente dos Softgoals formalizados e das métricas que vocês vincularam a eles no Passo 2.4.



Modelo de frase (template)

- "O sistema deve garantir [qualidade/softgoal], medida por [métrica], com [meta/limite]."



Exemplos preenchidos

- "O sistema deve fornecer explicabilidade para cada predição de risco, medida pela disponibilidade de valores SHAP por cliente." (origem: Softgoal Explicabilidade)
- "O sistema deve processar toda a base de clientes em lote em menos de 2 horas." (origem: Softgoal Baixa latência / prazo semanal)

 **ENTREGÁVEL DESTE PASSO:** Um Requisito Não-Funcional (RNF) redigido para cada Softgoal formalizado no Passo 2.3, usando a métrica definida no Passo 2.4.

ID	Requisito Não-Funcional (RNF)	Origem no modelo (Softgoal/Métrica)
RNF-01	O sistema deve garantir baixa taxa de falso positivo na sinalização de anomalias, medida pela precisão sobre o conjunto de teste, com valor superior à taxa base de anomalias do próprio conjunto avaliado.	Softgoal 1 (Baixa taxa de falso positivo / alta precisão)
RNF-02	O sistema deve garantir a localização das métricas responsáveis pela anomalia, medida pela disponibilidade do erro de reconstrução decomposto por dimensão de entrada, para cada janela sinalizada.	Softgoal 2 (Interpretabilidade)
RNF-03	O sistema deve garantir custo de treino viável no ambiente disponível, medido pela conclusão do treino sem uso de GPU dedicada.	Softgoal 3 (Custo computacional de treino viável)
RNF-04	O sistema deve garantir cobertura das degradações que só se manifestam na combinação das métricas, medida pelo recall sobre o conjunto de teste, com valor superior ao de um detector por limiar aplicado a cada métrica isoladamente, avaliado no mesmo volume de alerta.	Softgoal 4 (Cobertura de degradações multivariadas)

PASSO 4.3 Redigir os Requisitos de Dados (RD)

Um Requisito de Dados descreve o que precisa ser coletado, integrado ou tratado — nasce das Entidades, do Dataset Preparado e das transformações mapeadas na Fase 3.

Modelo de frase (template)

• "O sistema deve integrar/coletar/tratar [dado], proveniente de [fonte], aplicando [transformação], para alimentar [RF correspondente]."

Exemplo preenchido (streaming)

• "O sistema deve integrar dados de Cadastro do Cliente, Histórico de Visualização, Atendimentos ao Suporte e Pagamentos, tratando valores nulos e agregando o histórico de visualização em 'horas assistidas por semana', para alimentar o requisito RF-01."

 **ENTREGÁVEL DESTE PASSO:** Um ou mais Requisitos de Dados (RD), cobrindo as fontes e transformações da Fase 3, cada um referenciando o RF que ele alimenta.

ID	Requisito de Dados (RD)	RF que este dado alimenta
RD01	O sistema deve consumir as 38 métricas operacionais já coletadas pela infraestrutura de monitoramento, preservando a ordem temporal original dos registros.	RF-01, RF-04

ID	Requisito de Dados (RD)	RF que este dado alimenta
RD02	O sistema deve tratar os registros com valores ausentes ou não numéricos das Métricas Operacionais do Servidor, aplicando coerção para nulo seguida de descarte da linha.	RF-01, RF-04
RD03	O sistema deve preservar o pareamento posicional entre as métricas de teste e seus rótulos, descartando a linha em ambas as fontes sempre que qualquer uma apresentar valor ausente.	RF-07
RD04	O sistema deve padronizar as 38 métricas por z-score, provenientes das Métricas Operacionais do Servidor, aplicando média e desvio-padrão estimados exclusivamente sobre a partição de treino.	RF-01, RF-04, RF-05
RD05	O sistema deve converter a série padronizada das Métricas Operacionais do Servidor em janelas de 50 timesteps consecutivos com deslocamento de 1.	RF-01, RF-04, RF-06

PASSO 4.4 Definir o Critério de Aceitação (fechando o ciclo com o negócio)

Por fim, reconectem tudo ao Indicador de negócio definido lá no Passo 1.2 — é isso que prova que os requisitos, uma vez implementados, geram valor real, e não apenas um modelo tecnicamente correto.

Modelo de frase (template)

- "Este conjunto de requisitos será considerado bem-sucedido se [indicador] atingir [meta], observado em [período/frequência]."

Exemplo preenchido (streaming)

- "Este conjunto de requisitos será considerado bem-sucedido se a taxa mensal de churn cair de 5% para 4,25% em até 6 meses após o lançamento."

 **ENTREGÁVEL DESTE PASSO:** Uma frase de critério de aceitação, conectando os RF/RNF/RD ao Indicador de negócio da Fase 1.

Este conjunto de requisitos será considerado bem-sucedido se o detector sinalizar ao menos 85% dos eventos anômalos conhecidos do SMD (recall), mantendo precisão superior à taxa base de anomalias do conjunto avaliado (9,46% na machine-1-1), verificado a cada nova versão do modelo e registrado em artifacts/results.json.

Como reconhecer um requisito bem escrito

Use sempre 'o sistema deve...' (nunca 'seria bom se' ou 'o ideal seria'). Um requisito por frase — não amarrem duas exigências na mesma sentença. Ele precisa ser testável: alguém de fora do grupo deveria conseguir dizer, olhando o sistema pronto, se aquele requisito foi ou não atendido. E ele precisa ser rastreável: sempre cite de qual elemento do modelo GR4ML (Decision Goal, Softgoal, Entidade) aquele requisito se originou — é essa rastreabilidade que prova que a elicitação foi feita de ponta a ponta, e não inventada na hora de escrever o documento.

CHECKPOINT

A tarefa só está completa quando existe uma lista numerada de RFs, RNFs e RDs, cada um rastreável a um elemento específico dos modelos das Fases 1 a 3, e um critério de aceitação ligado ao Indicador de negócio.



Estrutura do documento a ser entregue

- 1. Contexto do projeto (Fase 0)
- 2. Diagrama e tabelas da Business View (Fase 1)
- 3. Tabelas de tarefas/algoritmos/softgoals/métricas da Analytics Design View (Fase 2)
- 4. Diagrama de pipeline da Data Preparation View (Fase 3)
- 5. Frase de verificação final preenchida
- 6. Lista consolidada de Requisitos Funcionais, Não-Funcionais e de Dados, com critério de aceitação (Fase 4)
- 7. Reflexão crítica (½ página): o ML era realmente necessário aqui? O que a formalização dos Softgoals e a tradução para requisitos revelaram que não estava claro na conversa inicial com o stakeholder?

Reflexão crítica do grupo

O ML era realmente necessário aqui? Em parte. A alternativa honesta é um limiar fixo por métrica, barato e transparente; o que justifica o modelo é a falha que esse baseline não cobre — degradações que só se manifestam na combinação das 38 métricas, sem que nenhuma delas cruze individualmente o seu limiar. Foi ela que virou o Softgoal 4 e, dele, o RNF-04. Só que esse baseline nunca foi medido por nós: enquanto a comparação não existir, a necessidade do ML está argumentada, não demonstrada.

A formalização revelou três coisas. Primeiro, a distância entre desejo e resultado: "poucos falsos alarmes" parecia óbvio até virar métrica — o modelo atinge 88% de recall e 25,3% de precisão, porque o limiar no percentil 99,5 privilegia sensibilidade e paga com ruído de alerta. Sem essa tradução, teríamos prometido 80% de alertas úteis contra um resultado três vezes menor. Segundo, um requisito que o código não atende: o RNF-02 pede o erro de reconstrução por dimensão, e a implementação devolve o erro médio da janela. Terceiro, o limite do próprio dado: como as métricas são anonimizadas, é possível ranquear dimensões, mas nunca afirmar qual componente falhou.

Fica uma limitação de fundo: o indicador de negócio é o tempo até a identificação, que o SMD não permite medir — recall e precisão são proxies, e a ponte com o valor de negócio segue hipotética por construção do exercício. Os próximos passos coerentes são medir o baseline de limiar isolado e calibrar o limiar para equilibrar precisão e recall, em vez de otimizar apenas a detecção.
